



TECHNICKÁ UNIVERZITA V LIBERCI
**Fakulta mechatroniky, informatiky
a mezioborových studií**



Moderní metody zpracování signálů

Komprimované vzorkování

Zbyněk Koldovský



evropský
sociální
fond v ČR



EVROPSKÁ UNIE



MINISTERSTVO ŠKOLSTVÍ,
MLÁDEŽE A TĚLOVÝCHOVY



OP Vzdělávání
pro konkurenceschopnost

Projekt ESF CZ.1.07/2.2.00/28.0050
**Modernizace didaktických metod
a inovace výuky technických
předmětů.**

INVESTICE DO ROZVOJE VZDĚLÁVÁNÍ

Část I

Komprimované vzorkování

Nyquist–Shannonův vzorkovací teorém

Vzorkovací teorém: Necht' $x[n] = x(nT_s)$,

$$f_s \geq 2f_m,$$

kde f_m je nejvyšší frekvence v $x(t)$. Potom

$$x(t) = \sum_{n=-\infty}^{+\infty} x[n] \operatorname{sinc} \left(\frac{t - nT_s}{T_s} \right) \quad \text{Shannonova rekonstrukce}$$

Nyquist–Shannonův vzorkovací teorém

Vzorkovací teorém: Necht' $x[n] = x(nT_s)$,

$$f_s \geq 2f_m,$$

kde f_m je nejvyšší frekvence v $x(t)$. Potom

$$x(t) = \sum_{n=-\infty}^{+\infty} x[n] \operatorname{sinc} \left(\frac{t - nT_s}{T_s} \right) \quad \text{Shannonova rekonstrukce}$$

- Podmínka dokonalé rekonstrukce: signál $x(t)$ má omezené spektrum

Nyquist–Shannonův vzorkovací teorém

Vzorkovací teorém: Necht' $x[n] = x(nT_s)$,

$$f_s \geq 2f_m,$$

kde f_m je nejvyšší frekvence v $x(t)$. Potom

$$x(t) = \sum_{n=-\infty}^{+\infty} x[n] \operatorname{sinc} \left(\frac{t - nT_s}{T_s} \right) \quad \text{Shannonova rekonstrukce}$$

- Podmínka dokonalé rekonstrukce: signál $x(t)$ má omezené spektrum
- Zmírnění požadavku: $f_s \geq 2f_d$, kde f_d je šířka pásma signálu

Jak dál?

- Množství získaných dat \times množství získané informace

Jak dál?

- Množství získaných dat \times množství získané informace
- Neuniformní vzorkování, komprese, ...

Jak dál?

- Množství získaných dat \times množství získané informace
- Neuniformní vzorkování, komprese, . . .
- *Řídké signály*

Řídký signál

- Vektorizovaný signál $\mathbf{x} = (x[1], \dots, x(N))^T$

Řídký signál

- Vektorizovaný signál $\mathbf{x} = (x[1], \dots, x(N))^T$
- k -řídký signál má maximálně k nenulových hodnot

Řídký signál

- Vektorizovaný signál $\mathbf{x} = (x[1], \dots, x(N))^T$
- k -řídký signál má maximálně k nenulových hodnot
- Definujeme tzv. 0-normu vektoru, která je rovna počtu jeho nenulových hodnot. k -řídký signál splňuje

$$\|\mathbf{x}\|_0 \leq k$$

Řídký signál

- Vektorizovaný signál $\mathbf{x} = (x[1], \dots, x(N))^T$
- k -řídký signál má maximálně k nenulových hodnot
- Definujeme tzv. 0-normu vektoru, která je rovna počtu jeho nenulových hodnot. k -řídký signál splňuje

$$\|\mathbf{x}\|_0 \leq k$$



- Signál transformovaný do jiné oblasti (např. frekvenční pomocí DFT) již řídký být nemusí. Transformaci můžeme zapsat pomocí transf. matice

$$\mathbf{y} = \Psi^T \mathbf{x}$$

Většinou uvažujeme jen ortogonální transformace tj., které splňují $\Psi\Psi^T = \mathbf{I}$ (např. DFT).



Řídké signály - příklady (1)

Řídký signál v čase:





Řídké signály - příklady (1)

Řídký signál v čase:





Řídký signál ve frekvenčním pásmu:





Řídké signály - příklady (2)

Lidská řeč:





Řídké signály - příklady (2)

Lidská řeč:



Fotografie:



Kompresa řídkého signálu

- 1 Transformace \mathbf{x} do oblasti, ve které je řídký.

$$\mathbf{y} = \Psi^T \mathbf{x}$$

Ψ musíme znát.

Kompresa řídkého signálu

- 1 Transformace \mathbf{x} do oblasti, ve které je řídký.

$$\mathbf{y} = \Psi^T \mathbf{x}$$

Ψ musíme znát.

- 2 Ukládáme pouze významné koeficienty \mathbf{y} . Tedy ukládáme index koeficientu a jeho hodnotu. Např.

$$y_S[k] = \begin{cases} y[k] & |y[k]| > \epsilon \\ 0 & |y[k]| \leq \epsilon \end{cases}$$

Kompresa řídkého signálu

- 1 Transformace \mathbf{x} do oblasti, ve které je řídký.

$$\mathbf{y} = \Psi^T \mathbf{x}$$

Ψ musíme znát.

- 2 Ukládáme pouze významné koeficienty \mathbf{y} . Tedy ukládáme index koeficientu a jeho hodnotu. Např.

$$y_s[k] = \begin{cases} y[k] & |y[k]| > \epsilon \\ 0 & |y[k]| \leq \epsilon \end{cases}$$

- 3 Použití: MPEG, JPEG, MP3, ...

Rekonstrukce

■ Platí

$$\mathbf{y} = \Psi^T \mathbf{x} \quad \Leftrightarrow \quad \mathbf{x} = \Psi^{-T} \mathbf{y} = \Psi \mathbf{y}.$$

Rekonstrukce

- Platí

$$\mathbf{y} = \Psi^T \mathbf{x} \quad \Leftrightarrow \quad \mathbf{x} = \Psi^{-T} \mathbf{y} = \Psi \mathbf{y}.$$

- Komprese: \mathbf{y} nahradíme \mathbf{y}_S (načteme z komprimovaného formátu).

Rekonstrukce

- Platí

$$\mathbf{y} = \Psi^T \mathbf{x} \quad \Leftrightarrow \quad \mathbf{x} = \Psi^{-T} \mathbf{y} = \Psi \mathbf{y}.$$

- Komprese: \mathbf{y} nahradíme \mathbf{y}_S (načteme z komprimovaného formátu).
- Rekonstrukce:

$$\hat{\mathbf{x}} = \Psi \mathbf{y}_S$$

Rekonstrukce

- Platí

$$\mathbf{y} = \Psi^T \mathbf{x} \quad \Leftrightarrow \quad \mathbf{x} = \Psi^{-T} \mathbf{y} = \Psi \mathbf{y}.$$

- Kompresi: \mathbf{y} nahradíme \mathbf{y}_S (načteme z komprimovaného formátu).
- Rekonstrukce:

$$\hat{\mathbf{x}} = \Psi \mathbf{y}_S$$

- Jelikož Ψ je ortogonální, platí


$$\|\hat{\mathbf{x}} - \mathbf{x}\|_2 = \|\Psi \hat{\mathbf{y}}_S - \Psi \mathbf{y}\|_2 = \|\Psi(\hat{\mathbf{y}}_S - \mathbf{y})\|_2 = \underbrace{\|\mathbf{y}_S - \mathbf{y}\|_2}_{\text{malé}}$$

kde $\|\cdot\|_2$ je euklidovská (tzv. ℓ_2) norma


$$\|\mathbf{x}\|_2 = \sqrt{\sum_{k=1}^N |x[k]|^2}$$

Kompresa + Rekonstrukce

Original image



Reconstruction of 3x25000 coefficients



Vzorkování v bázi Φ

Formální popis vzorkování v bázi $\Phi = (\varphi_1, \dots, \varphi_N)$

$$y[k] = \varphi_k^T \mathbf{x} = \langle \mathbf{x}, \varphi_k \rangle$$

Vzorkování v bázi Φ

Formální popis vzorkování v bázi $\Phi = (\varphi_1, \dots, \varphi_N)$

$$y[k] = \varphi_k^T \mathbf{x} = \langle \mathbf{x}, \varphi_k \rangle$$

Celý navzorkovaný signál

$$\mathbf{y} = \Phi^T \mathbf{x}$$

Vzorkování v bázi Φ

Formální popis vzorkování v bázi $\Phi = (\varphi_1, \dots, \varphi_N)$

$$y[k] = \varphi_k^T \mathbf{x} = \langle \mathbf{x}, \varphi_k \rangle$$

Celý navzorkovaný signál

$$\mathbf{y} = \Phi^T \mathbf{x}$$

Příklady:

- $\varphi_k(\ell) = \delta(\ell - k + 1)$ (“klasické” vzorkování v časové oblasti, $\Phi = \mathbf{I}$)
- $\varphi_k(\ell) = e^{j\frac{2\pi(\ell-1)(k-1)}{N}}$ (vzorkování ve frekvenčním pásmu, $\Phi \equiv \text{DFT}$)
- $\varphi_k(\ell) \dots$ wavelety
- $\varphi_k(\ell)$ náhodné \dots noiselety

Komprimované vzorkování

Compressed Sensing

Compressive Sampling

- Vzorkujeme v bázi Φ

$$\mathbf{y} = \Phi^T \mathbf{x}$$

Komprimované vzorkování

Compressed Sensing

Compressive Sampling

- Vzorkujeme v bázi Φ

$$\mathbf{y} = \Phi^T \mathbf{x}$$

- ...ale pouze m koeficientů (rovnou komprimujeme) $m \leq n$

$$\Phi \dots n \times m$$

Komprimované vzorkování

Compressed Sensing

Compressive Sampling

- Vzorkujeme v bázi Φ

$$\mathbf{y} = \Phi^T \mathbf{x}$$

- ... ale pouze m koeficientů (rovnou komprimujeme) $m \leq n$

$$\Phi \dots n \times m$$

- Předpoklad: \mathbf{x} je řídký v bázi Ψ a naopak v bázi Φ řídký není.

Rekonstrukce

- Hledáme \mathbf{x} , které splňuje

$$\mathbf{y} = \Phi^T \mathbf{x}.$$

Těch je ale nekonečně mnoho.

Rekonstrukce

- Hledáme \mathbf{x} , které splňuje

$$\mathbf{y} = \Phi^T \mathbf{x}.$$

Těch je ale nekonečně mnoho.

- Hledáme proto takové \mathbf{x} , kdy $\Psi^T \mathbf{x}$ je co nejvíce řídké. Tedy

$$\min \|\Psi^T \mathbf{x}\|_0 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

Rekonstrukce

- Hledáme \mathbf{x} , které splňuje

$$\mathbf{y} = \Phi^T \mathbf{x}.$$

Těch je ale nekonečně mnoho.

- Hledáme proto takové \mathbf{x} , kdy $\Psi^T \mathbf{x}$ je co nejvíce řídké. Tedy

$$\min \|\Psi^T \mathbf{x}\|_0 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

- Tuto úlohu však nelze vyřešit v polynomiálním čase (NP-úplný problém). Hladové algoritmy pro přibližná řešení: (Basic) Matching Pursuit, Orthogonal Matching Pursuit, ...

Řešení pomocí minimalizace $\| \cdot \|_1$

■ ℓ_p norma

$$\|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^N |x[i]|^p}$$

Řešení pomocí minimalizace $\| \cdot \|_1$

■ ℓ_p norma

$$\|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^N |x[n]|^p}$$

■ ℓ_1 norma

$$\|\mathbf{x}\|_1 = \sum_{i=1}^N |x[n]|$$

Řešení pomocí minimalizace $\| \cdot \|_1$

- ℓ_p norma

$$\|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^N |x[n]|^p}$$





- ℓ_1 norma

$$\|\mathbf{x}\|_1 = \sum_{i=1}^N |x[n]|$$

- Řešíme

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

Proč je řešení s ℓ_1 normou řídké? (1)



Proč je řešení s ℓ_1 normou řídké? (2)

■ Naše úloha

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

Proč je řešení s ℓ_1 normou řídké? (2)

■ Naše úloha

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

■ Úloha lineárního programování

$$\min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \quad \text{za podm.} \quad \mathbf{Ax} = \mathbf{b} \quad \text{a} \quad \mathbf{x}_l \leq \mathbf{x} \leq \mathbf{x}_u$$

Proč je řešení s ℓ_1 normou řídké? (2)

■ Naše úloha

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

■ Úloha lineárního programování

$$\min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \quad \text{za podm.} \quad \mathbf{Ax} = \mathbf{b} \quad \text{a} \quad \mathbf{x}_l \leq \mathbf{x} \leq \mathbf{x}_u$$

■ Řešení úlohy lin. prog.:

Proč je řešení s ℓ_1 normou řídké? (2)

- Naše úloha

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

- Úloha lineárního programování

$$\min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \quad \text{za podm.} \quad \mathbf{Ax} = \mathbf{b} \quad \text{a} \quad \mathbf{x}_l \leq \mathbf{x} \leq \mathbf{x}_u$$

- Řešení úlohy lin. prog.:

- Existuje-li, leží ve vrcholu popř. celé stěně konvexního polyedru definovaného podmínkami.

Proč je řešení s ℓ_1 normou řídké? (2)

■ Naše úloha

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

■ Úloha lineárního programování

$$\min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \quad \text{za podm.} \quad \mathbf{Ax} = \mathbf{b} \quad \text{a} \quad \mathbf{x}_l \leq \mathbf{x} \leq \mathbf{x}_u$$

■ Řešení úlohy lin. prog.:

- Existuje-li, leží ve vrcholu popř. celé stěně konvexního polyedru definovaného podmínkami.
- **Simplexový algoritmus, Dantzig 1951.**

Proč je řešení s ℓ_1 normou řídké? (2)

■ Naše úloha

$$\min \|\Psi^T \mathbf{x}\|_1 \quad \text{za podm.} \quad \mathbf{y} = \Phi^T \mathbf{x}$$

■ Úloha lineárního programování

$$\min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \quad \text{za podm.} \quad \mathbf{Ax} = \mathbf{b} \quad \text{a} \quad \mathbf{x}_l \leq \mathbf{x} \leq \mathbf{x}_u$$

■ Řešení úlohy lin. prog.:

- Existuje-li, leží ve vrcholu popř. celé stěně konvexního polyedru definovaného podmínkami.
 - Simplexový algoritmus, Dantzig 1951.
- Úlohu lze přeformulovat na úlohu lin. prog. pomocí substituce $x = x_k - x_z$, kde $x_k \geq 0$ a $x_z \geq 0$. Potom $|x| = x_k + x_z$.

Vztah bází Φ a Ψ : Koherence

■ Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

Vztah bází Φ a Ψ : Koherence

- Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

- Jsou-li Φ a Ψ ortogonální, platí

$$\mu(\Phi, \Psi) \in [1, \sqrt{N}]$$

Vztah bází Φ a Ψ : Koherence

- Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

- Jsou-li Φ a Ψ ortogonální, platí

$$\mu(\Phi, \Psi) \in [1, \sqrt{N}]$$

- Říkáme, že Φ a Ψ jsou nekoherentní, je-li

$$\mu(\Phi, \Psi) = 1$$

Vztah bází Φ a Ψ : Koherence

- Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

- Jsou-li Φ a Ψ ortogonální, platí

$$\mu(\Phi, \Psi) \in [1, \sqrt{N}]$$

- Říkáme, že Φ a Ψ jsou nekoherentní, je-li

$$\mu(\Phi, \Psi) = 1$$

- Příklady:

Vztah bází Φ a Ψ : Koherence

- Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

- Jsou-li Φ a Ψ ortogonální, platí

$$\mu(\Phi, \Psi) \in [1, \sqrt{N}]$$

- Říkáme, že Φ a Ψ jsou nekoherentní, je-li

$$\mu(\Phi, \Psi) = 1$$

- Příklady:

- $\mu(\mathbf{I}, \mathbf{DFT}) = 1$, časová a frekvenční báze jsou nekoherentní

Vztah bází Φ a Ψ : Koherence

- Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

- Jsou-li Φ a Ψ ortogonální, platí

$$\mu(\Phi, \Psi) \in [1, \sqrt{N}]$$

- Říkáme, že Φ a Ψ jsou nekoherentní, je-li

$$\mu(\Phi, \Psi) = 1$$

- Příklady:

- $\mu(\mathbf{I}, \mathbf{DFT}) = 1$, časová a frekvenční báze jsou nekoherentní
- Koherence mezi noiselets a waveletovými bázemi je $\sqrt{2}$ (Haar), 2.2 (Daubechies D4), 2.9 (Daubechies D8) apod.

Vztah bází Φ a Ψ : Koherence

- Koherence báze Φ a Ψ

$$\mu(\Phi, \Psi) = \sqrt{N} \cdot \max_{1 \leq k, j \leq N} |\langle \varphi_k, \psi_j \rangle|$$

- Jsou-li Φ a Ψ ortogonální, platí

$$\mu(\Phi, \Psi) \in [1, \sqrt{N}]$$

- Říkáme, že Φ a Ψ jsou nekoherentní, je-li

$$\mu(\Phi, \Psi) = 1$$

- Příklady:

- $\mu(\mathbf{I}, \mathbf{DFT}) = 1$, časová a frekvenční báze jsou nekoherentní
- Koherence mezi noiselets a waveletovými bázemi je $\sqrt{2}$ (Haar), 2.2 (Daubechies D4), 2.9 (Daubechies D8) apod.
- Koherence náhodné báze s pevnou bází je s vysokou pravděpodobností rovna přibližně $\sqrt{2 \log(N)}$

Jak velké musí být m ?

Theorem

Nechť \mathbf{x} je S -řádké v bázi Ψ , tedy $\Psi^T \mathbf{x}$ má S nenulových koeficientů. Pokud

$$m \geq C \cdot \mu^2(\Phi, \Psi) \cdot S \cdot \log(N),$$

pak pravděpodobnost, že řešení úlohy minimalizující $\|\cdot\|_1$ přesně odpovídá \mathbf{x} , je blízká 1. C je konstanta.

Jak velké musí být m ?

Theorem

Nechť \mathbf{x} je S -řádké v bázi Ψ , tedy $\Psi^T \mathbf{x}$ má S nenulových koeficientů. Pokud

$$m \geq C \cdot \mu^2(\Phi, \Psi) \cdot S \cdot \log(N),$$

pak pravděpodobnost, že řešení úlohy minimalizující $\|\cdot\|_1$ přesně odpovídá \mathbf{x} , je blízká 1. C je konstanta.

- Čím menší je koherence bází Φ a Ψ , tím může být m menší.

Jak velké musí být m ?

Theorem

Nechť \mathbf{x} je S -řádké v bázi Ψ , tedy $\Psi^T \mathbf{x}$ má S nenulových koeficientů. Pokud

$$m \geq C \cdot \mu^2(\Phi, \Psi) \cdot S \cdot \log(N),$$

pak pravděpodobnost, že řešení úlohy minimalizující $\|\cdot\|_1$ přesně odpovídá \mathbf{x} , je blízká 1. C je konstanta.

- Čím menší je koherence bází Φ a Ψ , tím může být m menší.
- Logaritmická závislost na N .

Jak velké musí být m ?

Theorem

Nechť \mathbf{x} je S -řádké v bázi Ψ , tedy $\Psi^T \mathbf{x}$ má S nenulových koeficientů. Pokud

$$m \geq C \cdot \mu^2(\Phi, \Psi) \cdot S \cdot \log(N),$$

pak pravděpodobnost, že řešení úlohy minimalizující $\|\cdot\|_1$ přesně odpovídá \mathbf{x} , je blízká 1. C je konstanta.

- Čím menší je koherence bází Φ a Ψ , tím může být m menší.
- Logaritmická závislost na N .
- Lineární závislost na S .

Jak velké musí být m ?

Theorem

Nechť \mathbf{x} je S -řádké v bázi Ψ , tedy $\Psi^T \mathbf{x}$ má S nenulových koeficientů. Pokud

$$m \geq C \cdot \mu^2(\Phi, \Psi) \cdot S \cdot \log(N),$$

pak pravděpodobnost, že řešení úlohy minimalizující $\|\cdot\|_1$ přesně odpovídá \mathbf{x} , je blízká 1. C je konstanta.

- Čím menší je koherence bází Φ a Ψ , tím může být m menší.
- Logaritmická závislost na N .
- Lineární závislost na S .
- Je-li $\mu(\Phi, \Psi) = 1$, potřebujeme řádově $S \log N$ vzorků.

Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.

Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.
- “Náhodné” vzorkování: signál je s vysokou pravděpodobností dokonale rekonstruován.

Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.
- “Náhodné” vzorkování: signál je s vysokou pravděpodobností dokonale rekonstruován.
- Možnost minimalizovat jiná kritéria než $\| \cdot \|_1$.

Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.
- “Náhodné” vzorkování: signál je s vysokou pravděpodobností dokonale rekonstruován.
- Možnost minimalizovat jiná kritéria než $\| \cdot \|_1$.
- **Robustní metody získávání zarušeného signálu.**

Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.
- “Náhodné” vzorkování: signál je s vysokou pravděpodobností dokonale rekonstruován.
- Možnost minimalizovat jiná kritéria než $\| \cdot \|_1$.
- Robustní metody získávání zarušeného signálu.
- **Kódování, samoopravné kódy**



Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.
- “Náhodné” vzorkování: signál je s vysokou pravděpodobností dokonale rekonstruován.
- Možnost minimalizovat jiná kritéria než $\| \cdot \|_1$.
- Robustní metody získávání zarušeného signálu.
- Kódování, samoopravné kódy
- Vzorkování dat v bázi Φ , např. snímání ve frekvenční oblasti (Magnetic Resonance Imaging - MRI)

Závěr

- Získávání užitečné informace ze signálu bez potřeby signálu “rozumět”.
- “Náhodné” vzorkování: signál je s vysokou pravděpodobností dokonale rekonstruován.
- Možnost minimalizovat jiná kritéria než $\| \cdot \|_1$.
- Robustní metody získávání zarušeného signálu.
- Kódování, samoopravné kódy
- Vzorkování dat v bázi Φ , např. snímání ve frekvenční oblasti (Magnetic Resonance Imaging - MRI)
- A/I převodník, převod analogového signálu přímo na informaci, získávání dat může být “nákladné” - komprese již při vzorkování.

Literatura

-  E. J. Candes, M. B. Wakin, “An Introduction To Compressive Sampling,” *IEEE Signal Processing Magazine*, vol. 25, no. 2, pp. 21–30, March 2008.
-  R. Hrbáček, P. Rajmic, V. Veselý, J. Špiřík, “Řídké reprezentace signálů: komprimované snímání,” *Elektrorevue*, Vol. 67, pp. 1–8, 2011.

Tento materiál vznikl v rámci projektu ESF CZ.1.07/2.2.00/28.0050

Modernizace didaktických metod a inovace výuky technických předmětů,
který je spolufinancován Evropským sociálním fondem a státním rozpočtem ČR.