

#### Moderní metody zpracování signálů

Slepá separace signálů

Zbyněk Koldovský














# Slepá separace signálů





- Pozorované signály jsou neznámou směsí neznámých původních signálů
- Úlohou slepé separace (BSS) je získání původních signálů
- Slepá identifikace spočívá v odhadu parametrů systému, který signály smíchal.







#### Lineární modely směsí

Lineární model bez odrazů a zpoždění:

$$X = AS$$

Konvolutorní model

$$x_i(t) = \sum_{j=1}^{a} \sum_{\tau=0}^{+\infty} a_{ij}(\tau) s_j(t-\tau)$$

S, s<sub>j</sub>(t) - původní signály, j = 1,..., d
 X, x<sub>i</sub>(t) - pozorované směsi signálů, i = 1,..., m
 A - mixovací matice m × d







#### Počet signálů d vs. počet senzorů m

m > d Přeurčený systém lze redukovat na určený m = d, smysl má spíše je-li uvažován aditivní šum  $\mathbf{X} = \mathbf{AS} + \mathbf{N}$ .


m = d Úlohy hledání **A** nebo **S** nebo  $A^{-1}$  isou ekvivalentní.

$$X = AS$$
  $S = A^{-1}X$ 

*m* < *d* Nedourčený systém, úlohy separace a identifikace jsou odlišné.



## Metody slepé separace



#### Předpoklady o původních signálech S

- S jsou nezáporné: Rozklad X na nezáporné matice, NMF, NTD
- S isou řídké: Rozklad X takový, aby S byly co nejvíce řídké (SCA)
- S jsou nezávislé: Analýza nezávislých komponent (ICA -Independent Component Analysis)





Moderní metody zpracování signálů

Modernizace didaktických metod
a inovace výuky technických předmětů





# Analýza nezávislých komponent



# Analýza nezávislých komponent - ICA

- Lineární model bez odrazů a zpoždění: X = AS
- Počet původních signálů je stejný jako počet signálů měřených m = d. Matice **A** je čtvercová  $m \times m$
- Hledáme A nebo rovnou její inverzi A<sup>-1</sup>. Odhadovanou matici označíme W. Ideálně chceme, aby

 $WX \approx S$ 

Hledáme matici W takovou, aby WX byly nezávislé.







#### Nejednoznačnost řešení

- Řešení není jednoznačné: můžeme změnit pořadí a škálu signálů S a zůstanou nezávislé.
- W je řešení kdykoliv platí

$$WA = PD,$$

kde **P** je permutační matice (změna pořadí signálů) a **D** je diagonální (mění škálu signálů).

Je-li řešení až na tyto výjimky jednoznačné, říkáme, že je v podstatě jednoznačné (essentially unique).







#### Předzpracování (preprocessing) pomocí PCA

- Obecně platí: jsou-li signály nezávislé, pak jsou i nekorelované.
- Můžeme tedy signály X nejprve transformovat tak, aby byly nekorelované, čímž splníme nutnou (nikoliv však postačující) podmínku nezávislosti.

$$\mathbf{Z} = \mathbf{B}\mathbf{X}$$

- Hlavní komponenty jsou nekorelované (viz. předchozí přednáška), můžeme tedy k výpočtu B použít PCA.
- Vzhledem k nejednoznačnosti, škálu (rozptyl) signálů můžeme normovat. Platit tedy bude

$$\mathbf{C}_{\mathbf{Z}} = \frac{1}{N} \mathbf{Z} \mathbf{Z}^T = \mathbf{I}$$







# Předzpracování (preprocessing) pomocí PCA

Tuto vlastnost budou mít i signály

$$\mathbf{Y} = \mathbf{U}\mathbf{Z}$$

kdykoliv  $\mathbf{U}\mathbf{U}^T = \mathbf{I}$  ( $\mathbf{U}$  je ortogonální). Ověřte.

ICA můžeme formulovat tak, že hledáme ortogonální U tak, aby Y = UZ byly nezávislé.







#### Jak měřit nezávislost signálů?

 Potřebujeme definovat kritérium, které budeme optimalizovat vzhledem k U.

$$\mathbf{U}^* = \arg\min_{\mathbf{U}, \mathbf{U}\mathbf{U}^T = \mathbf{I}} J(\mathbf{U}\mathbf{Z})$$

- Existují tři hlavní způsoby:
  - Vzájemná informace Y
  - Vzájemná diagonalizace kovariančních matic bloků X
  - Vzájemná diagonalizace cross-kovariančních matic X







# Vzájemná informace

Vzájemná informace (multiinformace):

$$I(\mathbf{Y}) = \int_{\mathbb{R}^d} \ln \frac{f_{y_1, \dots, y_d}(y_1, \dots, y_d)}{\prod_{i=1}^d f_{y_i}(y_i)} f_{y_1, \dots, y_d}(y_1, \dots, y_d) dy_1, \dots, dy_d$$

Platí

$$I(\mathbf{Y}) = 0 \iff \mathbf{Y}$$
 jsou nezávislé

Matici U hledáme minimalizací vzájemné informace

$$\mathbf{U}^* = \arg\min_{\mathbf{U}} I(\mathbf{UZ})$$

Vlastnost vzájemné informace: pro **U** ortogonální platí

$$I(\mathbf{Y}) = \sum_{i=1}^{d} \underbrace{H(y_i)}_{\text{entropie}} + \text{const.}$$

minimalizujeme entropie signálů.







## Vzájemná diagonalizace kovariančních matic

Kovarianční matice ktého bloku signálů je

$$\mathbf{C}_k = \frac{1}{M} \mathbf{X}_k \mathbf{X}_k^T$$

kde  $X_k$  je ktý blok X a M jeho délka.

Platí

$$\mathbf{C}_k = \mathbf{A} \underbrace{ egin{array}{c} \mathbf{S}_k \mathbf{S}_k^T \ N \end{array}}_{ ext{kov. matrice } \mathbf{S}_k} \mathbf{A}^T$$

- S jsou nezávislé, takže jejich kovarianční matice jsou diagonální.
- Proto hledáme W tak, aby kovarianční matice WX<sub>k</sub> byly diagonální.







#### Vzájemná diagonalizace cross-kovariančních matic

Cross-kovarianční matice je definována

$$\mathbf{C}[\tau] = \frac{1}{N} \mathbf{X}[n] \mathbf{X}^{T}[n+\tau]$$

kde  $\mathbf{X}^T[n+\tau]$  značí matici  $\mathbf{X}$  posunutou o  $\tau$  vzorků.

Platí


$$\mathbf{C}[\tau] = \mathbf{A} \underbrace{\frac{\mathbf{S}[n]\mathbf{S}^T[n+ au]}{N}}_{\text{kov. matice } \mathbf{S}} \mathbf{A}^T$$

- S jsou nezávislé, takže jejich kovarianční matice jsou diagonální.
- Proto hledáme W tak, aby cross-kovarianční matice WX byly diagonální.









#### Rekonstrukce signálů pomocí ICA

- Získání signálů, které byly původně nezávislé, z jejich směsi.
- Analýza dat objevení skrytých (nezávislých) komponent
- Zpracování pomocí separace a rekonstrukce
  - Data separujeme na nezávislé komponenty

$$\mathbf{Y} = \mathbf{W}\mathbf{X}$$


- Určíme, které komponenty (ne)chceme. Nežádoucí komponenty vynulujeme (nebo nějak zpracujeme).
- Rekonstruujeme původní data

$$\hat{\mathbf{X}} = \mathbf{W}^{-1}\mathbf{Y}$$











Část III

# Slepá separace nedourčených směsí





#### Nedourčené směsi

Nedourčená směs

$$\mathbf{X} = \mathbf{AS}$$

kde **A** je obdélníková  $m \times d$ , kde m < d.

■ A nelze invertovat. Určit A (identifikace) a S (separace) jsou odlišné úlohy.







#### Slepá identifikace A pomocí rozkladu tenzoru

- Tenzor  $\mathcal{X}$ : 3 (a více) rozměrné pole s prvky  $X_{ijk}$
- Zvolíme tenzor tak, že \( \mathcal{X}\_{:,:,k} = \mathbb{R}\_k \), kde \( \mathbb{R}\_k \) je kovarianční matice \( k \text{tého bloku signálů } \mathbb{X} \).
- lacksquare  $\mathcal{X}$  má rozměry  $m \times m \times M$





#### Struktura tenzoru X

- **Z** modelu vyplývá:  $\mathbf{R}_k = \mathbf{A} \operatorname{diag}[\mathbf{c}_k] \mathbf{A}^T$
- Z toho plyne

$$X_{ijk} = \sum_{f=1}^{d} A_{if} A_{jf} C_{kf},$$

kde sloupce **C** jsou  $\mathbf{c}_k$ ,  $k = 1, \ldots, d$ .

Snažíme se tedy najít matice A a C, aby model X co nejlépe odpovídal X spočtenému z dat.







### Algoritmy

Matice A a C hledáme minimalizací

$$\|\mathcal{X} - \mathcal{I} \times_1 \boldsymbol{\mathsf{A}} \times_2 \boldsymbol{\mathsf{A}^\mathsf{T}} \times_3 \boldsymbol{\mathsf{C}}\|^2$$

Alternating Least-Squares (ALS), Gauss-Newton, Levenberg-Marquardt, . . .

- 🔈 A. Hyvärinen, J. Karhunen, and E. Oja, *Independent* Component Analysis, Wiley-Interscience, New York, 2001.
- Te-Won Lee, Independent Component Analysis: Theory and Applications, MA: Kluwer, Boston, 237 pp., 1998.
- P. Comon and C. Jutten, Handbook of Blind Source Separation: Independent Component Analysis and Applications, Academic Press, Elsevier Ltd., 859 pp., 2010.